Sistem Pendukung Keputusan dan Kecerdasan Bisnis (Edisi ke- 9 , Prentice Hall)

Bab 7:

Penambangan Teks dan Web

Tujuan pembelajaran

- Jelaskan penambangan teks dan pahami kebutuhan akan penambangan teks.
- Bedakan antara penambangan teks, penambangan web, dan penambangan data.
- Pahami berbagai area aplikasi penambangan teks.
- Pahami proses pelaksanaan proyek penambangan teks.
- Memahami berbagai metode untuk memberikan struktur pada data berbasis teks.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Tujuan pembelajaran

- Jelaskan penambangan web, tujuannya, dan manfaatnya.
- Pahami tiga cabang berbeda dari penambangan web.
  - Penambangan konten web
  - Penambangan struktur web
  - Penambangan penggunaan web
- Pahami penerapan dari ketiga paradigma penambangan ini.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Cuplikan Pembuka:

"Teks Pertambangan untuk Keamanan dan Kontraterorisme"

- Apa itu MITRE?
- Deskripsi masalah
- Solusi yang diusulkan
- Hasil
- Jawab dan diskusikan pertanyaan-pertanyaan kasus tersebut.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Cuplikan Pembuka: Menggali Teks untuk Keamanan...

Cluster 1

(L) Kampala
(L) Uganda
(P) Yoweri Museveni
(L) Sudan
(L) Khartoum
(L) Southern Sudan

Cluster 2

(P) Timothy McVeigh
(P) Oklahoma City
(P) Terry Nichols

Cluster 3

(E) election
(P) Norodom Ranariddh
(P) Norodom Sihanouk
(L) Bangkok
(L) Cambodia
(L) Phnom Penh
(L) Thailand
(P) Hun Sen
(O) Khmer Rouge
(P) Pol Pot

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Konsep Penambangan Teks

- 85-90 persen dari seluruh data perusahaan berada dalam bentuk yang tidak terstruktur (misalnya, teks).
- Ukuran data perusahaan yang tidak terstruktur meningkat dua kali lipat setiap 18 bulan.
- Mengakses sumber informasi ini bukanlah pilihan, melainkan kebutuhan untuk tetap kompetitif.
- Jawaban: penambangan teks
  - Suatu proses semi-otomatis untuk mengekstrak pengetahuan dari sumber data yang tidak

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Data versus Penambangan Teks

- Keduanya mencari pola-pola baru dan bermanfaat.
- Keduanya merupakan proses semi-otomatis.
- Perbedaannya terletak pada sifat data:
  - Data terstruktur versus data tidak terstruktur
  - Data terstruktur: dalam basis data
  - Data tidak terstruktur: dokumen Word, file PDF, cuplikan teks, file XML, dan sebagainya

Copyright ©2011 Pearson Education, Inc. Publishing as Prentice Hall

Konsep Penambangan Teks

- Manfaat penambangan teks sangat jelas, terutama di lingkungan data yang kaya teks.
  - misalnya, hukum (putusan pengadilan), penelitian akademis (artikel penelitian), keuangan (laporan triwulanan), kedokteran (ringkasan pasien keluar), biologi (interaksi molekuler), teknologi (berkas paten), pemasaran (komentar pelanggan), dll.
- Catatan komunikasi elektronik (misalnya, Email)
  - Penyaringan spam
  - Prioritas dan kategorisasi email
  - Pembuatan respons otomatis

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Area Aplikasi Penambangan Teks

- Ekstraksi informasi
- Pelacakan topik
- Ringkasan
- Kategorisasi
- Kekelompokan
- Konsep yang menghubungkan
- Menjawab pertanyaan

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Terminologi Penambangan Teks

- Data tidak terstruktur atau semi-terstruktur
- Korpus (dan korpora)
- Ketentuan
- Konsep
- Batang
- Kata-kata penghenti (dan kata-kata yang disertakan)
- Sinonim (dan polisemi)
- Tokenisasi

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Terminologi Penambangan Teks

- Kamus istilah
- Frekuensi kata
- Penandaan bagian ujaran
- Morfologi
- Matriks istilah per dokumen
  - Matriks kemunculan
- Dekomposisi nilai singular
  - Pengindeksan semantik laten

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Teks untuk Analisis Paten (lihat Kasus Aplikasi 7.2)

- Apa itu paten?
  - "Hak eksklusif yang diberikan oleh suatu negara kepada seorang penemu untuk jangka waktu terbatas sebagai imbalan atas pengungkapan suatu penemuan"
- Bagaimana cara kita melakukan analisis paten (PA)?
- Mengapa kita perlu melakukan PA (Physical Assistance)?
  - Apa saja manfaatnya?
  - Apa saja tantangannya?

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Pemrosesan Bahasa Alami (NLP)

- Menyusun struktur kumpulan teks
  - Pendekatan lama : bag-of-words
  - Pendekatan baru : pemrosesan bahasa alami
- NLP adalah…
  - sebuah konsep yang sangat penting dalam penambangan teks
  - subbidang kecerdasan buatan dan linguistik komputasional
  - studi tentang "pemahaman" bahasa manusia alami
- Penambangan teks berbasis sintaksis versus semantik

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Pemrosesan Bahasa Alami (NLP)

- Apa yang dimaksud dengan "Pemahaman"?
  - Manusia bisa memahami, bagaimana dengan komputer?
  - Bahasa alami bersifat samar dan bergantung pada konteks.
  - Pemahaman sejati membutuhkan pengetahuan yang luas tentang suatu topik.

  - Apakah komputer akan mampu memahami bahasa alami dengan cara yang sama/akurat seperti kita ?

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Pemrosesan Bahasa Alami (NLP)

- Tantangan dalam NLP
  - Penandaan bagian ujaran
  - Segmentasi teks
  - Disambiguasi makna kata
  - Ambiguitas sintaksis
  - Masukan yang tidak sempurna atau tidak teratur
  - Tindakan ucapan
- Mimpi komunitas AI
  - memiliki algoritma yang mampu secara otomatis membaca dan memperoleh pengetahuan dari teks.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Pemrosesan Bahasa Alami (NLP)

- WordNet
  - Sebuah basis data yang dikodekan secara manual dengan susah payah, berisi kata-kata bahasa Inggris, definisinya, kumpulan sinonim, dan berbagai hubungan semantik antar kumpulan sinonim.
  - Sumber daya utama untuk NLP
  - Diperlukan penyelesaian otomatisasi.
- Analisis Sentimen
  - Teknik yang digunakan untuk mendeteksi opini positif dan negatif terhadap produk dan layanan tertentu.
  - Lihat Kasus Aplikasi 7.3 untuk aplikasi CRM.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Kategori Tugas NLP

- Pengambilan informasi
- Ekstraksi informasi
- Pengenalan entitas bernama
- Menjawab pertanyaan
- Ringkasan otomatis
- Generasi dan pemahaman bahasa alami
- Terjemahan mesin
- Membaca dan menulis bahasa asing
- Pengenalan suara
- Pemeriksaan teks
- Pengenalan karakter optik

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks

- Aplikasi pemasaran
  - Memungkinkan CRM yang lebih baik.
- Aplikasi keamanan
  - ECHELON, OASIS
  - Deteksi penipuan (...)
- Kedokteran dan biologi
  - Identifikasi gen berdasarkan literatur (...)
- Aplikasi akademik
  - Analisis alur penelitian

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

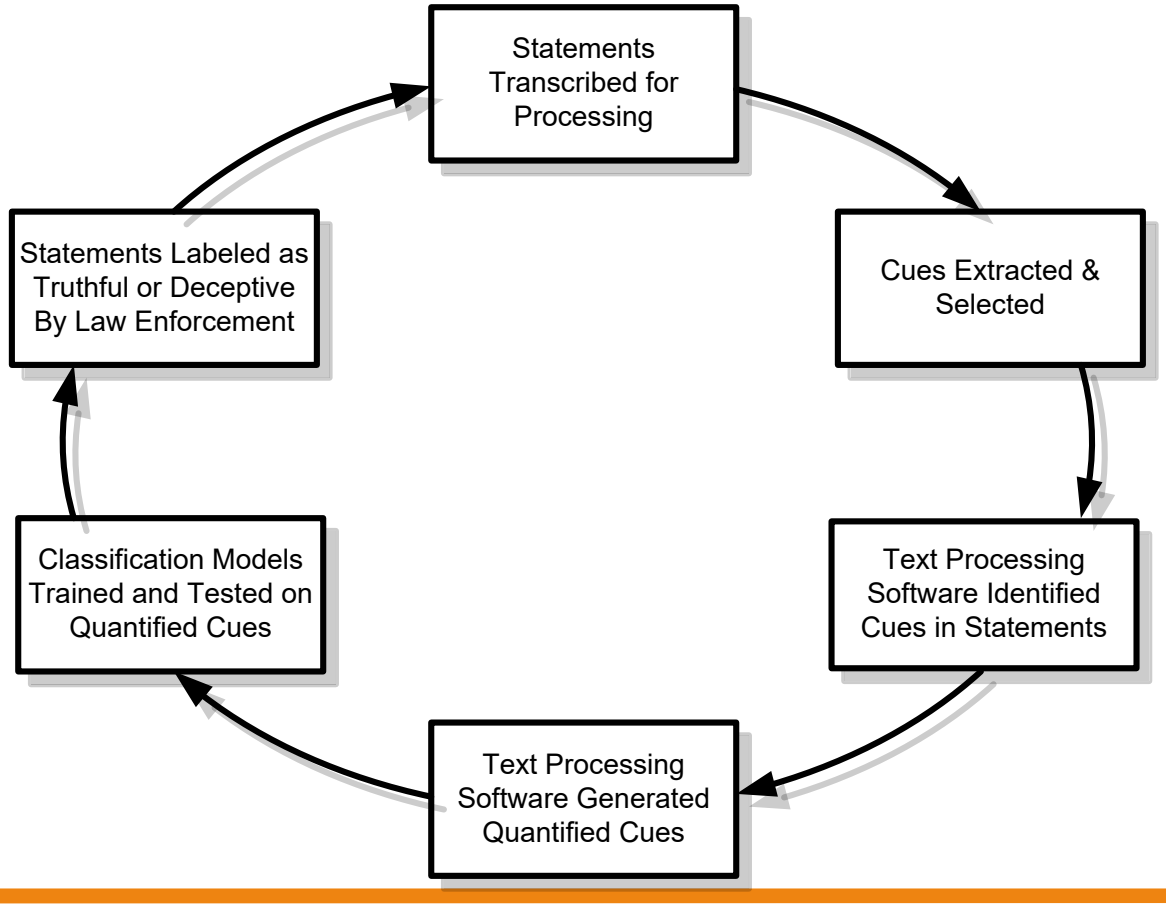
Aplikasi Penambangan Teks

- Studi Kasus 7.4: Menggali Kebohongan
- Deteksi penipuan
  - Masalah yang sulit
  - Jika deteksi hanya terbatas pada teks, maka masalahnya akan menjadi lebih sulit.
- Studi tersebut
  - menganalisis kesaksian berbasis teks dari orang-orang yang menjadi perhatian di pangkalan militer.
  - hanya menggunakan fitur berbasis teks (petunjuk)

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks

- Studi Kasus 7.4: Menggali Kebohongan



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks

- Studi Kasus 7.4: Menggali Kebohongan

Category	Example Cues
Quantity	Verb count, noun-phrase count, ...
Complexity	Avg. no of clauses, sentence length, …
Uncertainty	Modifiers, modal verbs, ...
Nonimmediacy	Passive voice, objectification, ...
Expressivity	Emotiveness
Diversity	Lexical diversity, redundancy, ...
Informality	Typographical error ratio
Specificity	Spatiotemporal, perceptual information …
Affect	Positive affect, negative affect, etc.

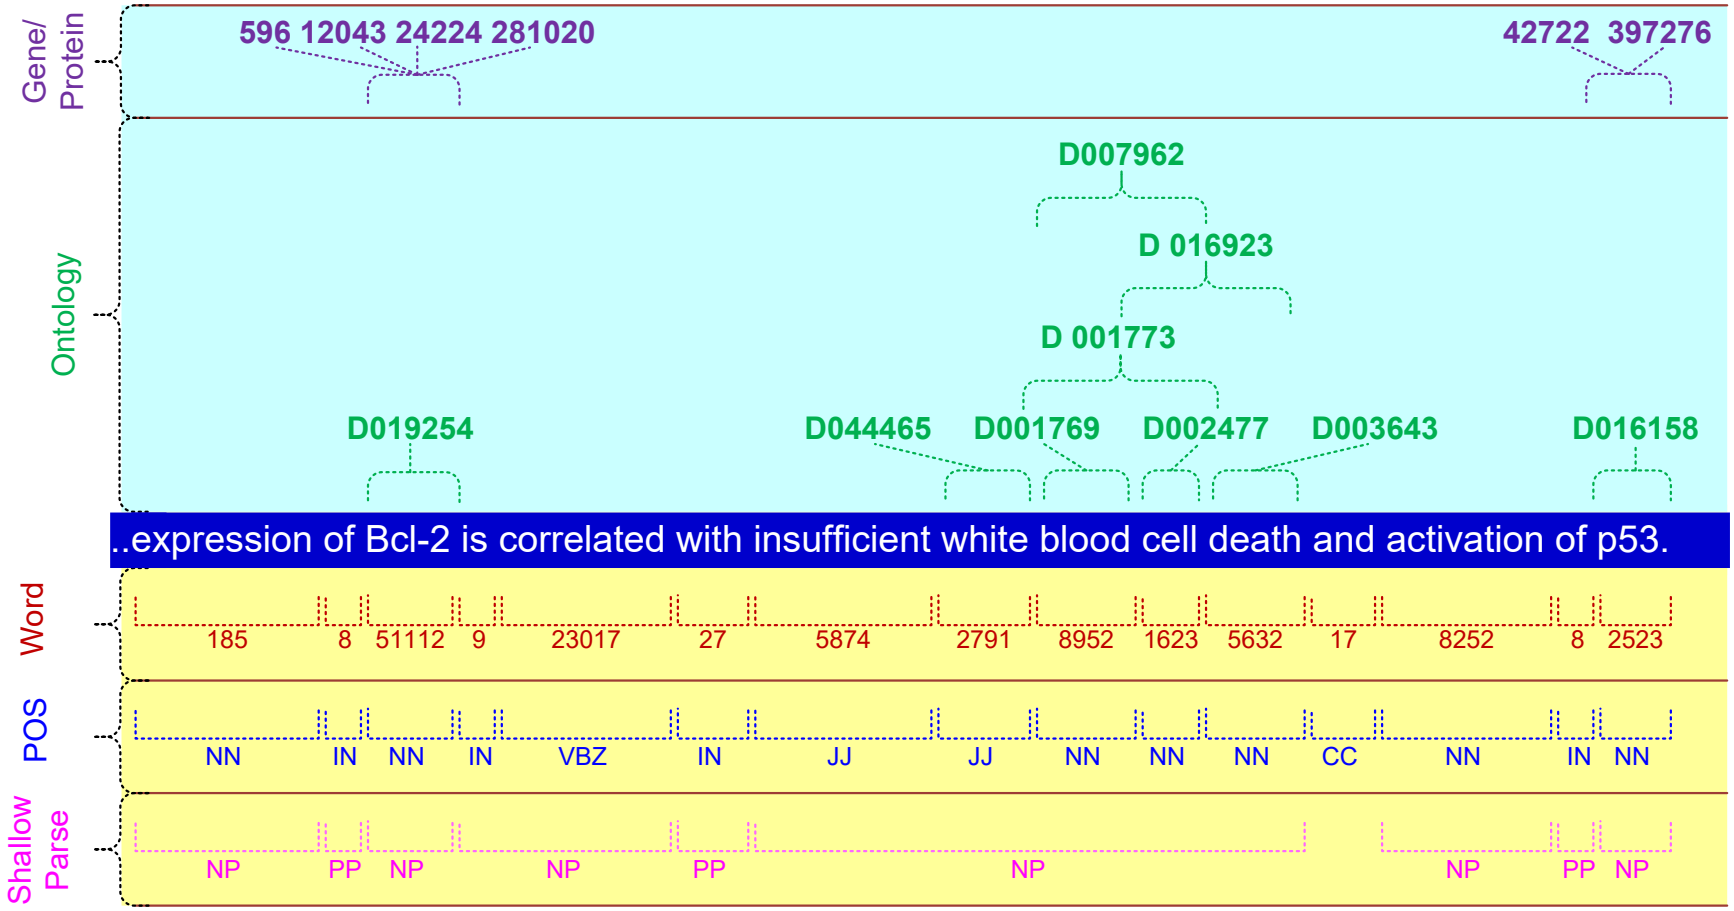
Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks

- Studi Kasus 7.4: Menggali Kebohongan
  - 371 pernyataan yang dapat digunakan dihasilkan
  - 31 fitur digunakan
  - Metode pemilihan fitur yang berbeda digunakan
  - Validasi silang 10 kali lipat digunakan.
  - Hasil (akurasi keseluruhan dalam %)
    - Regresi logistik 67,28
    - Pohon keputusan 71.60
    - Jaringan saraf 73.46

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

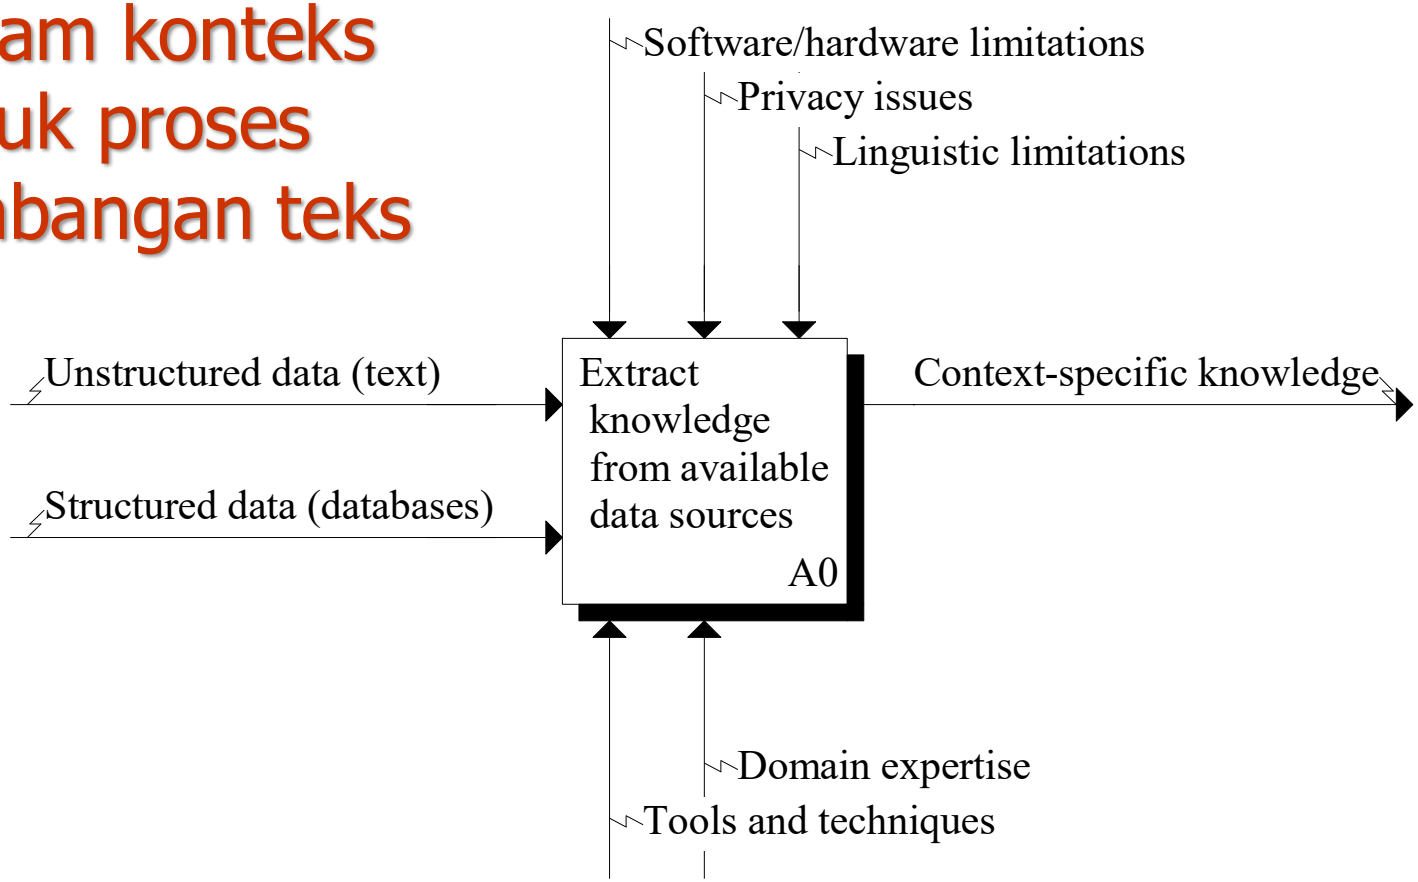
Aplikasi Penambangan Teks (identifikasi interaksi gen/protein)



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

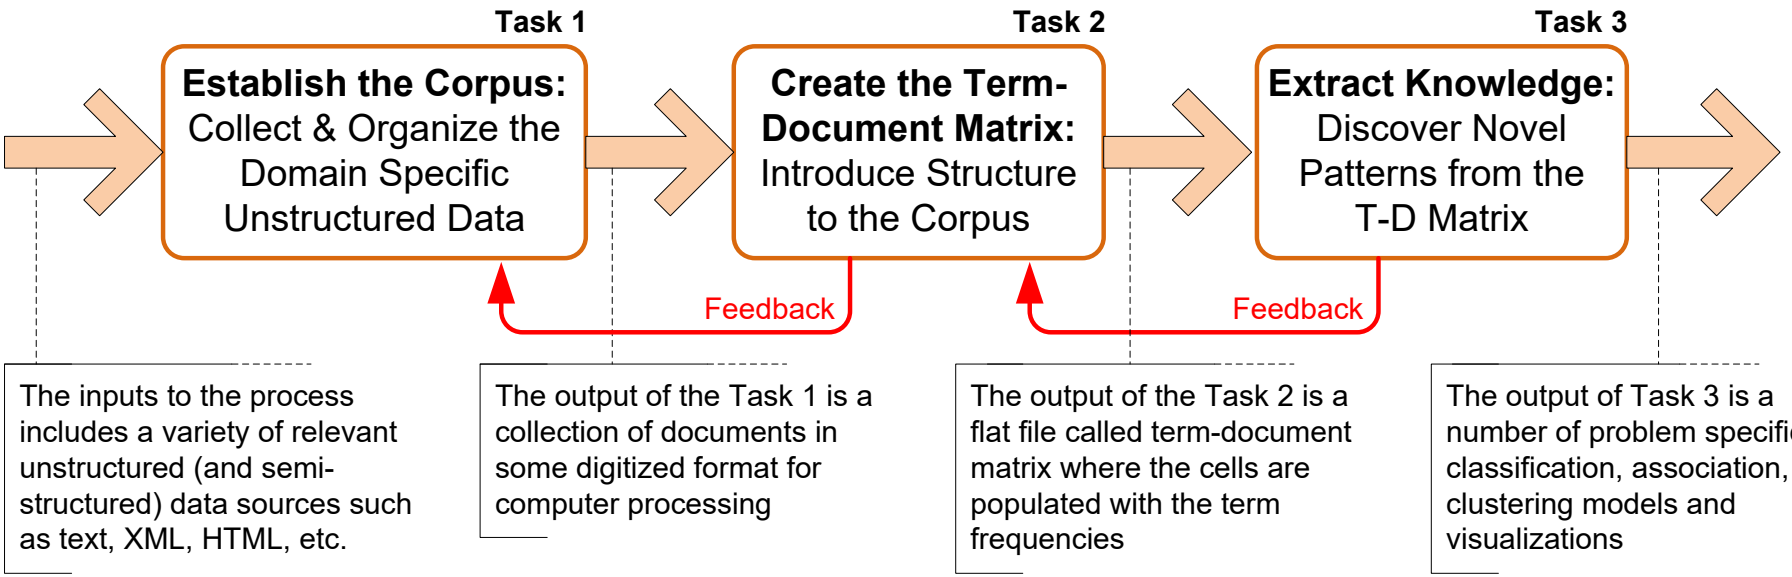
Proses Penambangan Teks

Diagram konteks untuk proses penambangan teks



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks



Proses penambangan teks tiga langkah

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks

- Langkah 1: Membangun korpus
  - Kumpulkan semua data tidak terstruktur yang relevan (misalnya, dokumen teks, file XML, email, halaman web, catatan singkat, rekaman suara...).
  - Digitalisasikan dan standarisasi koleksi (misalnya, semuanya dalam file teks ASCII).
  - Tempatkan koleksi tersebut di tempat yang sama (misalnya, dalam file datar, atau dalam direktori sebagai file terpisah).

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks

- Langkah 2: Buat Matriks Istilah per Dokumen

Terms / Documents	investment risk	project management	software engineering	development	SAP	...	
Document 1	1			1			
Document 2		1					
Document 3			3		1		
Document 4		1					
Document 5			2	1			
Document 6	1			1			
...							

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks

- Langkah 2: Membuat Matriks Istilah-per-Dokumen (TDM), lanjutan.
  - Apakah semua ketentuan harus disertakan?
    - Kata-kata penghenti, termasuk kata-kata
    - Sinonim, homonim
    - Batang
  - Apa representasi terbaik dari indeks (nilai dalam sel)?
    - Jumlah baris; frekuensi biner; frekuensi logaritmik;
    - Frekuensi dokumen terbalik

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks

- Langkah 2: Membuat Matriks Istilah-per-Dokumen (TDM), lanjutan.
  - TDM adalah matriks jarang (sparse matrix). Bagaimana kita dapat mengurangi dimensi TDM?
    - Panduan - seorang ahli di bidangnya akan menjelaskannya.
    - Menghilangkan istilah yang jarang muncul di sedikit dokumen (?)
    - Transformasikan matriks menggunakan dekomposisi nilai singular (SVD).
    - SVD mirip dengan analisis komponen utama.

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Proses Penambangan Teks

- Langkah 3: Mengekstrak pola/pengetahuan
  - Klasifikasi (kategorisasi teks)
  - Pengelompokan (pengelompokan teks secara alami)
    - Meningkatkan daya ingat pencarian
    - Tingkatkan ketepatan pencarian
    - Menyebar/mengumpulkan
    - Pengelompokan khusus kueri
  - Asosiasi
  - Analisis Tren (...)

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks (identifikasi tren penelitian dalam literatur)

- Menggali literatur Sistem Informasi yang telah dipublikasikan
  - Jurnal Sistem Informasi Manajemen (MISQ)
  - Jurnal Sistem Informasi Manajemen (JMIS)
  - Penelitian Sistem Informasi (ISR)

  - Mencakup periode 12 tahun (1994-2005)
  - Sebanyak 901 makalah disertakan dalam penelitian ini.
  - Hanya abstrak makalah yang digunakan.
  - 9 klaster dihasilkan untuk analisis lebih

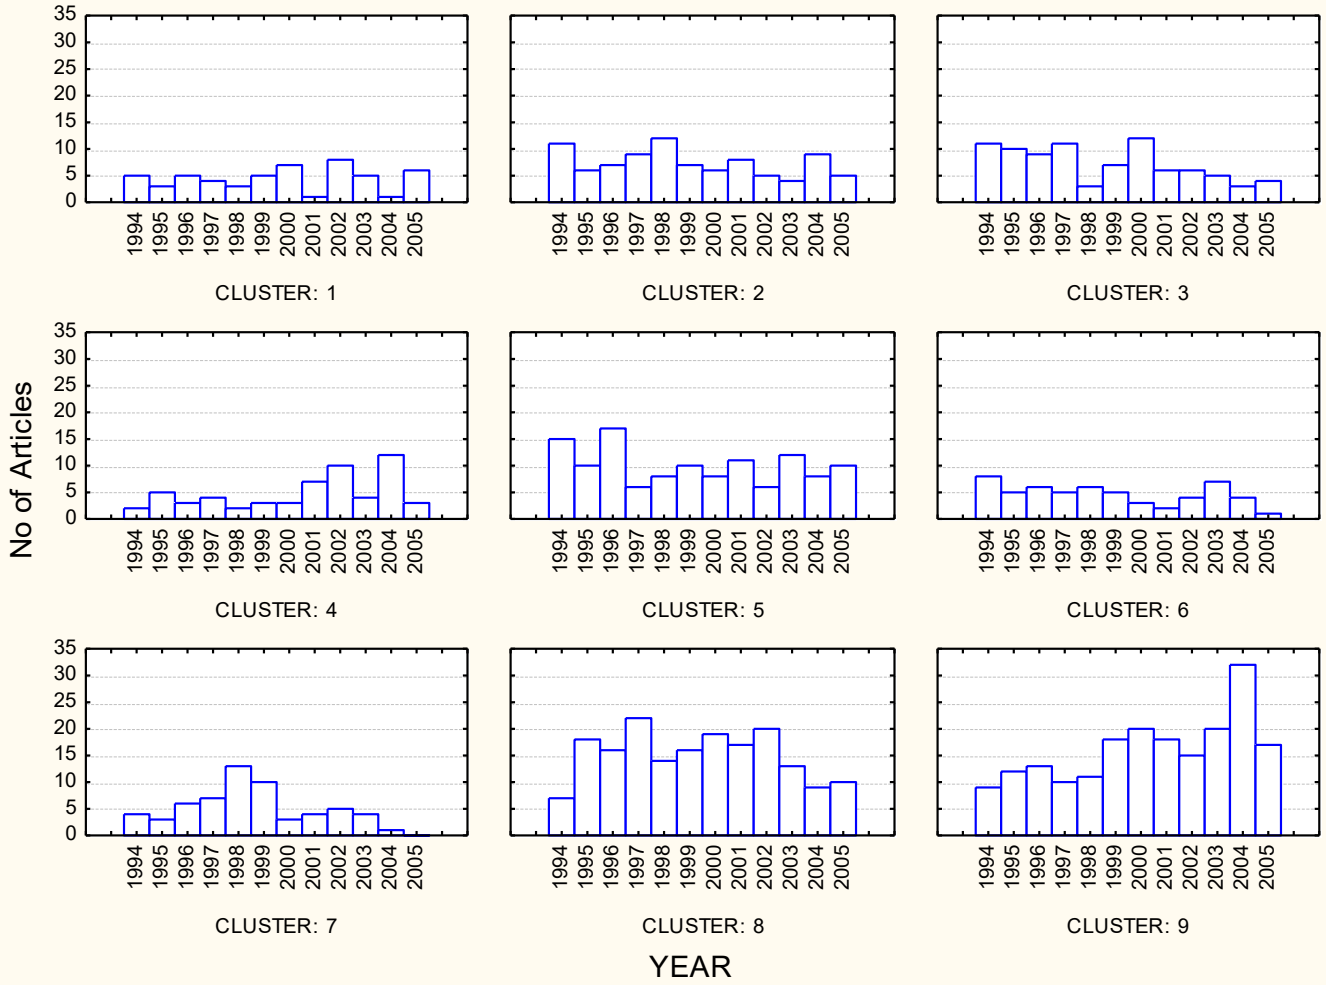
Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks (identifikasi tren penelitian dalam literatur)

Journal	Year	Author(s)	Title	Vol/No	Pages	Keywords	Abstract
MISQ	2005	A. Malhotra, S. Gosain and O. A. El Sawy	Absorptive capacity configurations in supply chains: Gearing for partner-enabled market knowledge creation	29/1	145-187	knowledge management supply chain absorptive capacity interorganizational information systems configuration approaches	The need for continual value innovation is driving supply chains to evolve from a pure transactional focus to leveraging interorganizational partner ships for sharing
ISR	1999	D. Robey and M. C. Boudreau	Accounting for the contradictory organizational consequences of information technology: Theoretical directions and methodological implications	2-Oct	167-185	organizational transformation impacts of technology organization theory research methodology intraorganizational power electronic communication mis implementation culture systems	Although much contemporary thought considers advanced information technologies as either determinants or enablers of radical organizational change, empirical studies have revealed inconsistent findings to support the deterministic logic implicit in such arguments. This paper reviews the contradictory
JMIS	2001	R. Aron and E. K. Clemons	Achieving the optimal balance between investment in quality and investment in self-promotion for information products	18/2	65-88	information products internet advertising product positioning signaling signaling games	When producers of goods (or services) are confronted by a situation in which their offerings no longer perfectly match consumer preferences, they must determine the extent to which the advertised features of
…	…	…	…	…	…	…	…

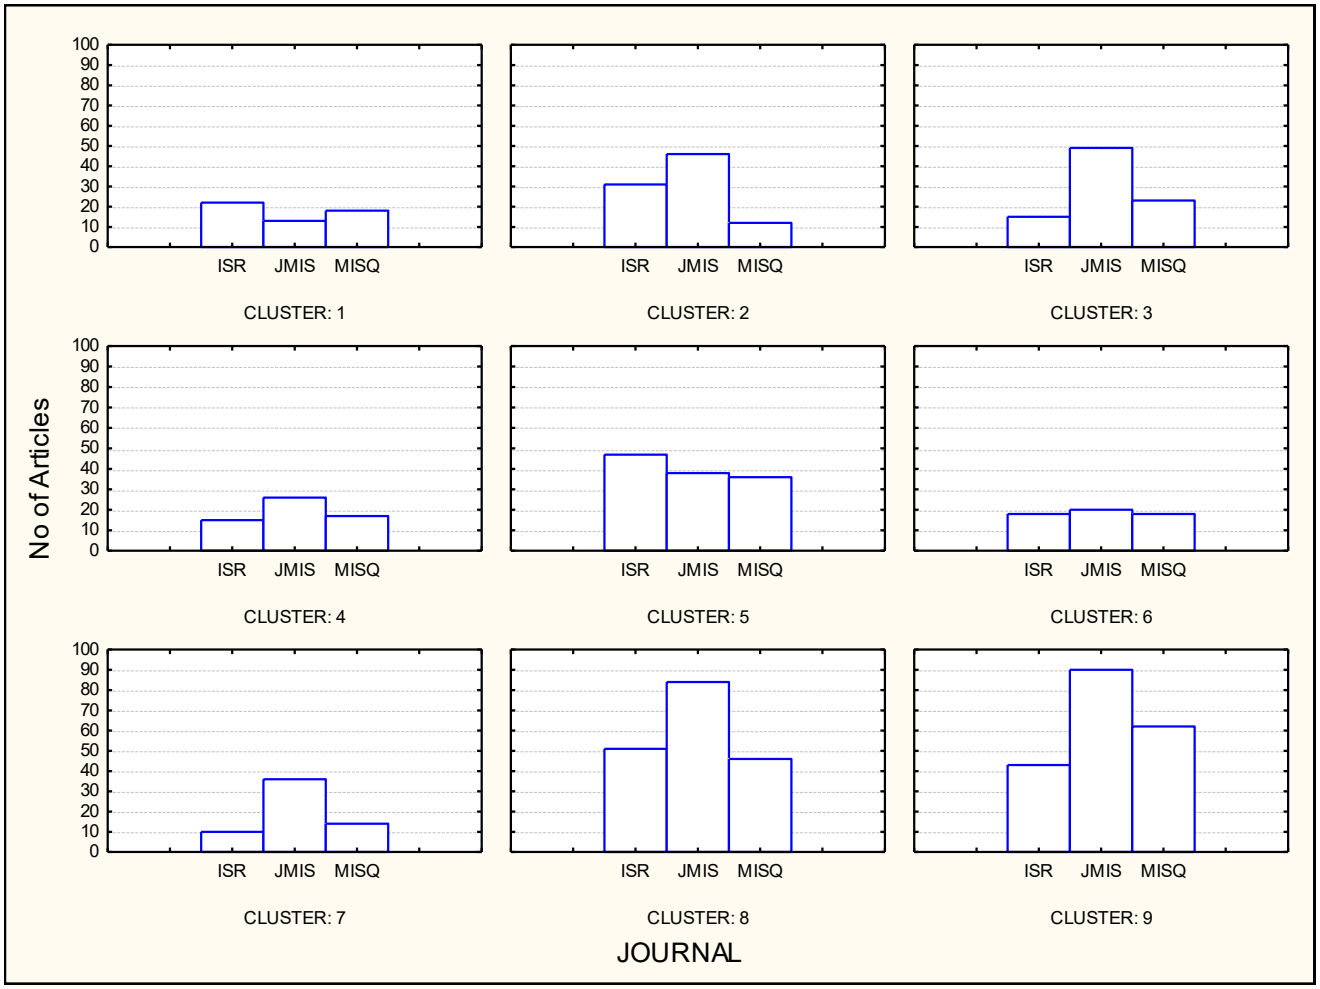
Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks (identifikasi tren penelitian dalam literatur)



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Aplikasi Penambangan Teks (identifikasi tren penelitian dalam literatur)



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Alat Penambangan Teks

- Alat Perangkat Lunak Komersial
  - Penambang Teks SPSS PASW
  - SAS Enterprise Miner
  - Penambang Data Statistika
  - ClearForest, …
- Alat Perangkat Lunak Gratis
  - RapidMiner
  - GERBANG
  - Spy-EM, …

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

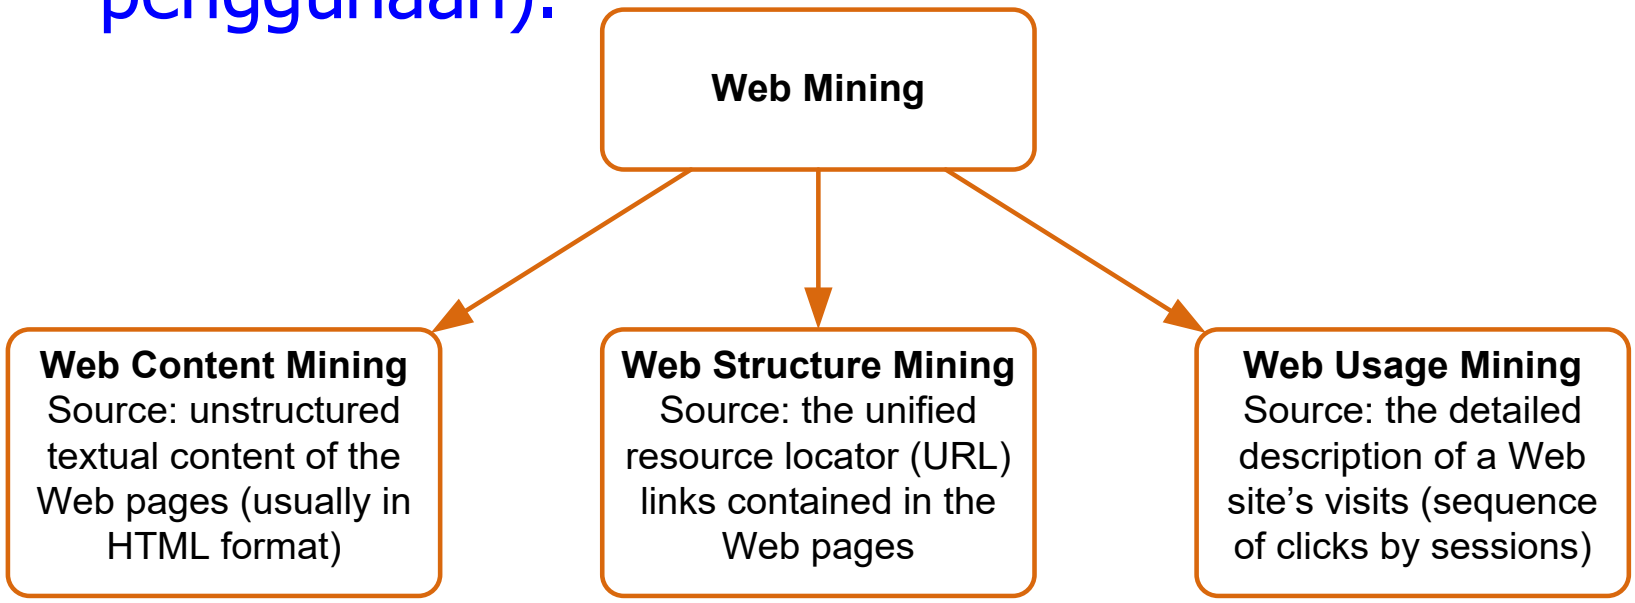
Gambaran Umum Penambangan Web

- Web adalah gudang data terbesar.
- Data tersedia dalam format HTML, XML, dan teks.
- Tantangan (dalam memproses data Web)
  - Web terlalu luas untuk penambangan data yang efektif.
  - Web terlalu rumit.
  - Web terlalu dinamis.
  - Web tidak terbatas pada domain tertentu.
  - Internet memiliki segalanya.
- Peluang dan tantangannya sangat besar!

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Web

- Penambangan web (atau penambangan data web) adalah proses menemukan hubungan intrinsik dari data web (tekstual, tautan, atau penggunaan).



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Konten/Struktur Web

- Penambangan konten tekstual di Web
- Pengumpulan data melalui perayap web.

- Halaman web menyertakan hyperlink.
  - Halaman-halaman yang berwibawa
  - Pusat
  - algoritma pencarian topik yang diinduksi hyperlink (HITS)

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Penggunaan Web

- Ekstraksi informasi dari data yang dihasilkan melalui kunjungan halaman web dan transaksi...
  - data yang tersimpan dalam log akses server, log perujuk, log agen, dan cookie sisi klien
  - karakteristik pengguna dan profil penggunaan
  - metadata, seperti atribut halaman, atribut konten, dan data penggunaan.
- Data clickstream
- Analisis aliran klik

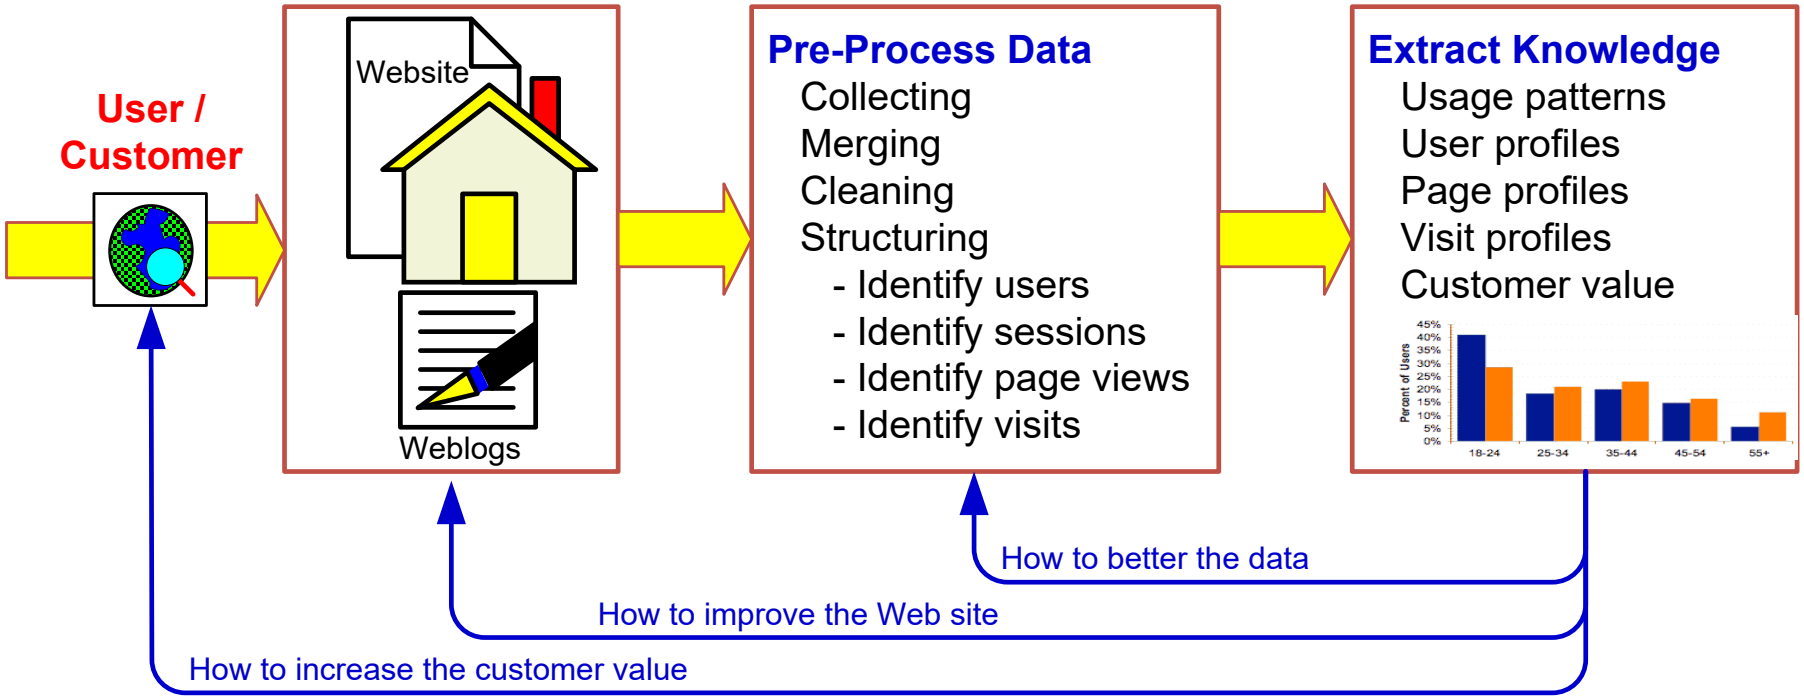
Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Penambangan Penggunaan Web

- Aplikasi penambangan penggunaan web
  - Tentukan nilai seumur hidup klien.
  - Merancang strategi pemasaran silang antar produk.
  - Evaluasi kampanye promosi
  - Targetkan iklan elektronik dan kupon kepada kelompok pengguna berdasarkan pola akses pengguna.
  - Memprediksi perilaku pengguna berdasarkan aturan yang telah dipelajari sebelumnya dan profil pengguna.
  - Menyajikan informasi dinamis kepada pengguna berdasarkan minat dan profil mereka...

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

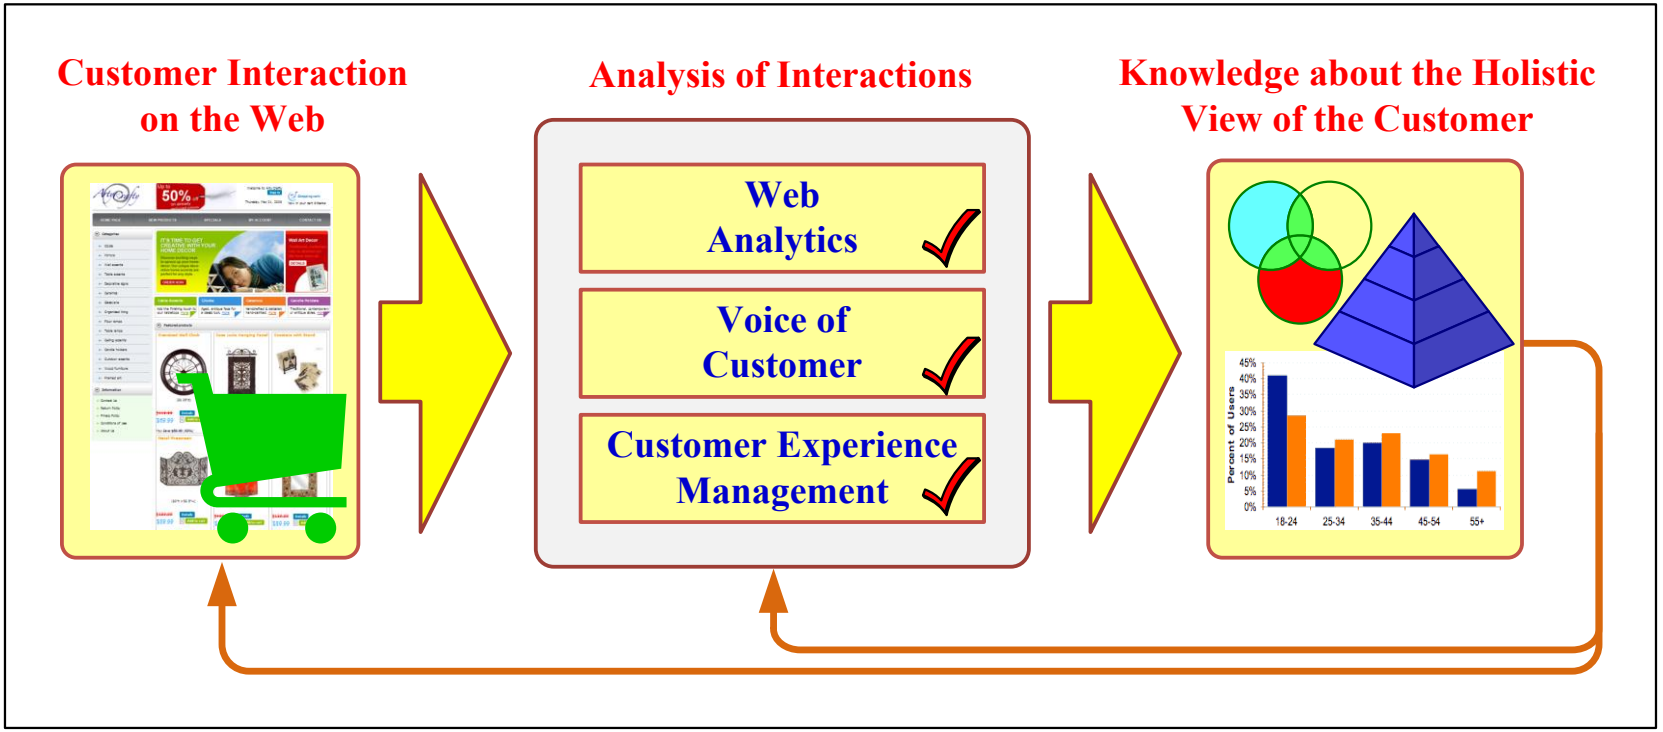
Penambangan Penggunaan Web (analisis aliran klik)



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Kisah Sukses Penambangan Web

- Amazon.com, Ask.com, Scholastic.com, ...
- Ekosistem Optimasi Situs Web



Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Alat Penambangan Web

Product Name	URL
Angoss Knowledge WebMiner	angoss.com
ClickTracks	clicktracks.com
LiveStats from DeepMetrix	deepmetrix.com
Megaputer WebAnalyst	megaputer.com
MicroStrategy Web Traffic Analysis	microstrategy.com
SAS Web Analytics	sas.com
SPSS Web Mining for Clementine	spss.com
WebTrends	webtrends.com
XML Miner	scientio.com

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Akhir Bab

- Pertanyaan/komentar…

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall

Seluruh hak dilindungi undang-undang. Tidak ada bagian dari publikasi ini yang boleh direproduksi, disimpan dalam sistem pengambilan, atau ditransmisikan, dalam bentuk apa pun atau dengan cara apa pun, elektronik, mekanik, fotokopi, perekaman, atau lainnya, tanpa izin tertulis sebelumnya dari penerbit. Dicetak di Amerika Serikat.

Hak cipta © 2011 Pearson Education, Inc.
Diterbitkan dengan nama Prentice Hall

Copyright © 2011 Pearson Education, Inc. Publishing as Prentice Hall